МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

"МИРЭА - Российский технологический университет"

РТУ МИРЭА

Институт информационных технологий (ИТ)
Кафедра математического обеспечения и стандартизации информационных технологий (МОСИТ)

ОТЧЁТ ПО ПРАКТИЧЕСКОМУ ЗАДАНИЮ №2

по дисциплине «Структуры и алгоритмы обработки данных»

Тема: «Хеширование и организация быстрого поиска данных»

Отчет представлен к рассмотрению:
Студент группы ИНБО-01-20 «28» сентября 2021 г. _____ Салов В.Д.
(подпись)

Преподаватель «28» сентября 2021 г. _____ Сорокин А.В.
(подпись)

Москва, 2021 г.

СОДЕРЖАНИЕ

Цель работы

Получение навыков по разработке хеш-таблиц и их применению.

Постановка задачи

Разработать приложение, которое использует хеш-таблицу для организации прямого доступа к записям файла, структура записи которого приведена в варианте.

Вариант 9.

Тип хеш-таблицы (способ реализации коллизий)	Структура записи файла (ключ – подчеркнутое поле)
Цепное хеширование	Страховой полис: номер, компания, фамилия владельца

Имеющиеся данные:

- хеш-таблица для реализации коллизий по методу *Цепное хеширование*;
- двоичный файл с записями фиксированной длины;
- структура записи файла: номер, компания, фамилия владельца.

Результат:

- приложение, выполняющее операции;
- управление хеш-таблицей: вставка ключа, удаление ключа, нахождение ключа в хеш-таблице, рехеширование.

Управление файлом:

- посредством хеш-таблицы: считывание записи из файла при поиске записи;
- добавление записи в файл, удаление записи из файла, чтение записи файла по заданному номеру записи.

Подход к решению.

1) Разработан класс хеш-таблицы, содержащий размер хеш-таблицы и методы добавления, удаления, получения элемента, рехеширования и вывода в консоль.
2) Создан класс узла однонаправленного списка, содержащий информационную часть и ссылку на следующий узел.
3) Добавлены классы для работы с файлом и для управления однонаправленным списком.

Класс для работы с файлом включает в себя методы получения и изменения строки, переключения между файлами (при рехешировании), а также генератор прохода по всем строкам, содержащим информационную часть узлов.

Класс однонаправленного списка содержит конструктор, генерирующий список по строке, методы добавления и удаления элементов, а также метод получения строкового представления.

Таким образом данные классы инкапсулируют работу с файлом и работу с однонаправленным списком в простой интерфейс.

4) Разработаны методы обработки хеш-таблицы:

- Вставка: вычисление хеша нового элемента и его расположение в соответствующем списке.
- Удаление: нахождение соответствующего списка и удаление из него элемента по ключу.
- Поиск: нахождение по хеш-функции соответствующего списка и поиск нужного элемента в нём.
- Вывод: вывод содержимого файла в консоль.
- Рехеширование: увеличение размера таблицы и распределение по ней всех элементов.

5) Для хранения данных используется текстовый файл со следующей структурой:

<номер>,<компания>,<фамилия >;<номер>,<компания>,<фамилия>
<номер>,<компания>,<фамилия>

Каждый список записывается в строку, соответствующей его номеру; каждый узел отделяется от другого с помощью символа «;»; каждое поле узла отделяется от другого с помощью символа «,».

Добавлены методы редактирования файла:

- Для добавления записи в файл строка, соответствующая данному элементу, заменяется на новое строковое отображение списка.
- Для удаления записи из файла строка, соответствующая данному элементу, заменяется на новое строковое отображение списка.

Алгоритмы операций на псевдокоде.

Вставка в таблицу:

func вставка(узел_списка):

h := хеш-функция(узел_списка.ключ);

ul := однонаправленный_список(строка_в_файле_на_позиции (h));

ul.добавить(узел_списка);

записать_в_файл_строку_на_позицию(ul.строка, h);

Удаление из таблицы:

func удаление(ключ):

h := хеш-функция(узел_списка.ключ);

ul := однонаправленный_список(строка_в_файле_на_позиции (h));

ul.удалить(ключ);

записать_в_файл_строку_на_позицию(ul.строка, h);

Поиск по ключу:

func поиск(ключ):

h := хеш-функция(узел_списка.ключ);

ul := однонаправленный_список(строка_в_файле_на_позиции (h));

res := ul.поиск(ключ);

возврат res;

Код приложения.

Класс узла списка:

```
class Node:
    def __init__(self, number, company, name):
        self.number = number
        self.company = company
        self.name = name
        self.next = None

    @classmethod
    def from_string(cls, line: str):
        lines = line.split(',')
        return Node(int(lines[0]), lines[1], lines[2])

    def __str__(self):
        return f'{self.number},{self.company},{self.name}'
```

Класс однонаправленного списка:

```
from .Node import Node

class UnidirectionalList:
    def __init__(self, line: str):
        self.len = 0
        self.start = None
        if line != '' and line != '\n':
            lines = line.split(';')
            for node_line in lines:
                self.add(Node.from_string(node_line))

    def __str__(self):
        current_node = self.start
        res = []
        while current_node is not None:
            res.append(str(current_node))
            current_node = current_node.next
        res = ';'.join(res[::-1]).replace('\n', '')
        return res

    def add(self, node: Node):
        old_start = self.start
        self.start = node
        node.next = old_start
        self.len += 1
        return self.len

    def remove(self, key: int):
        if self.start is not None:
            if self.start.number == key:
                self.start = self.start.next
            else:
                current_node = self.start
                while current_node.next is not None:
                    if current_node.next.number == key:
                        current_node.next = current_node.next.next
                    else:
                        current_node = current_node.next

    def get(self, key: int):
        current_node = self.start
        while current_node is not None:
            if current_node.number == key:
                return current_node
            current_node = current_node.next
```

Класс для чтения файла:

```
class FileWorking:
    def __init__(self):
        self.work_file = 'file1.txt'
        self.temp_file = 'file2.txt'

    def get_line(self, n: int):
        file = open(self.work_file, 'r')
        res = file.readlines()[n]
        file.close()
        res.replace('\n', '')
        return res

    def set_line(self, n: int, line: str):
        file = open(self.work_file, 'r')
        lines = file.readlines()
        lines = list(map(lambda x: x.replace('\n', ''), lines))
        file.close()
        lines[n] = line
        file = open(self.work_file, 'w')
        file.writelines(map(lambda x: x + '\n', lines))
        file.close()

    def set_lines_count(self, n):
        file = open(self.work_file, 'w')
        file.writelines(['\n'] * n)
        file.close()

    def iterate_throw_old_nodes(self):
        file = open(self.temp_file, 'r')
        lines = file.readlines()
        file.close()
        for line in lines:
            for node_line in line.split(';'):
                if node_line != '\n':
                    yield node_line

    def swap_files(self):
        self.work_file, self.temp_file = self.temp_file, self.work_file

    def get_all_lines(self):
        file = open(self.work_file, 'r')
        lines = file.readlines()
        file.close()
        return lines


fw = FileWorking()
```

Класс хеш-таблицы:

```
from .UnidirectionalList import UnidirectionalList, Node
from .FileWorking import fw

class HashTable:
    def __init__(self):
        self.size = 2
        fw.set_lines_count(2)

    def hash(self, x: int):
        return x % self.size

    def add(self, number: int, company: str, name: str):
        node = Node(number, company, name)
        h = self.hash(node.number)
        ul = UnidirectionalList(fw.get_line(h))
        count = ul.add(node)
        fw.set_line(h, str(ul))
        if count > self.size * 0.75:
            self.rehash()

    def remove(self, number):
        h = self.hash(number)
        ul = UnidirectionalList(fw.get_line(h))
        ul.remove(number)
        fw.set_line(h, str(ul))

    def get(self, number):
        h = self.hash(number)
        ul = UnidirectionalList(fw.get_line(h))
        return str(ul.get(number)).replace('\n', '')

    def rehash(self):
        fw.swap_files()
        self.size *= 2
        fw.set_lines_count(self.size)
        for node_line in fw.iterate_throw_old_nodes():
            self.__add_node(Node.from_string(node_line))

    def fill_from_file(self, file_path):
        file = open(file_path, 'r')
        for line in file:
            line = line.replace('\n', '')
            if line != '':
                self.__add_node(Node.from_string(line))

    def print(self):
        print('-------')
        print(''.join(fw.get_all_lines()), end='')
        print('-------')

    def __add_node(self, node: Node):
        self.add(node.number, node.company, node.name)
```

Результаты выполнения операций с хеш-таблицами.

Для проведения тестирования было добавлено несколько элементов.

Код теста:

```
from Lab2N import *

hs = HashTable()
hs.add(1, 'ab', 'gh')
hs.print()
hs.add(2, 'cd', 'ij')
hs.print()
hs.add(5, 'ef', 'kl')
hs.print()
```

Результат:

```
-------


1,ab,gh
-------
-------
2,cd,ij
1,ab,gh
-------
-------


1,ab,gh;5,ef,kl
2,cd,ij


-------
```

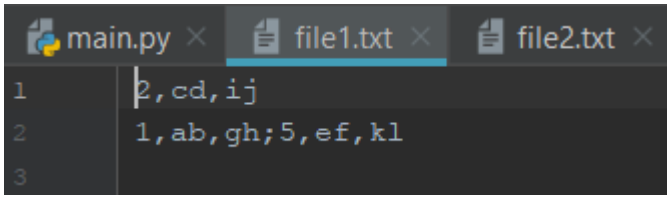

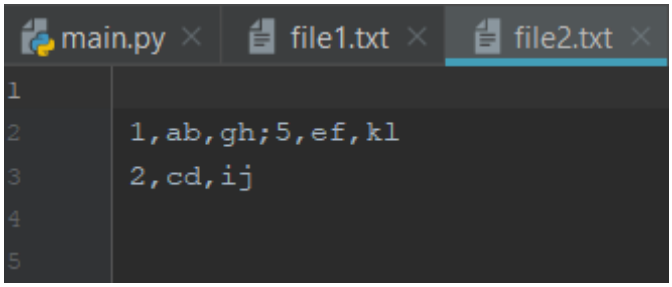

Рисунок 1 – ввод элементов.

Таблица вывелась три раза с новыми элементами. После добавления третьего элемента произошло **рехеширование**. Это можно увидеть по размеру таблицы. Также произошла **коллизия**, и элемент с ключом «5» встал в список за элементом с ключом «1», так как значение их хеш-функций совпало.

Добавим ещё несколько элементов, а затем удалим часть элементов.

Код теста:

```
hs.add(7, 'abc', 'pqr')
hs.add(9, 'def', 'stu')
hs.add(12, 'ghi', 'vwx')
hs.add(13, 'jkl', 'yza')
hs.add(14, 'mno', 'bcd')
hs.print()

hs.remove(12)
hs.remove(5)
hs.print()
```

Результат:

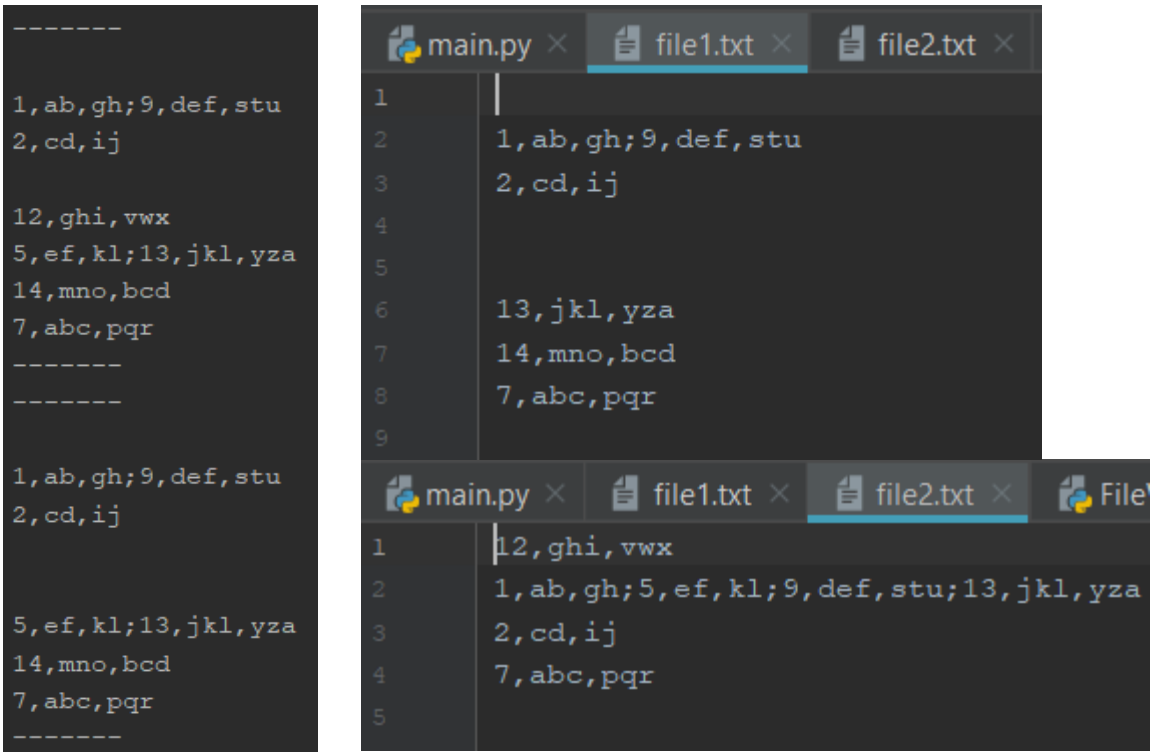

Рисунок 2 – Результаты тестирования.

Как можно заметить, указанные нам записи добавились, а после удалились. Далее протестируем возможность поиска элементов по ключу.

Код теста:

```
print(hs.get(9))
print(hs.get(2))
print(hs.get(5))
```

Результат:

```
9,def,stu
2,cd,ij
None
```

Рисунок 3 – Результат тестирования.

Программа работает верно, поскольку существующие элементы были найдены и выведены на экран, а не существующие – нет, что можно понять из надписи «None».

Скриншоты содержания файла и хеш-таблицы.

Полный вывод программы при тестировании:

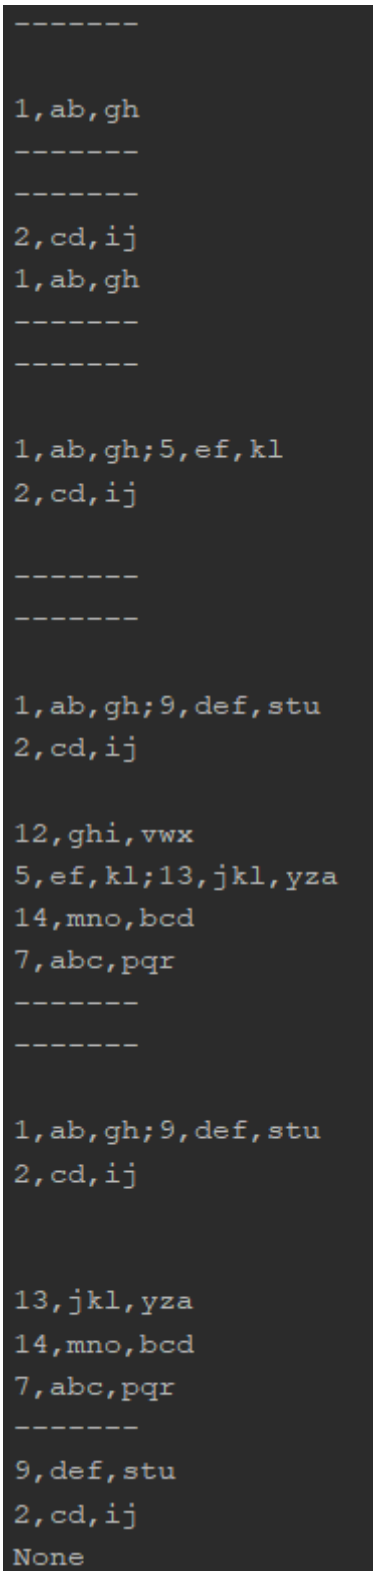

Рисунок 4 – Полный вывод программы при тестировании

Содержимое файла:

```
1,ab,gh;9,def,stu
2,cd,ij


13,jkl,yza
14,mno,bcd
7,abc,pqr
```

Рисунок 5 – Содержимое файла.

Время поиска элемента с заданным ключом.

Заполним хеш-таблицу большим количеством элементов. Для примера заполним её случайным образом, добавляя в неё элементы со значением ключа от 0 до 9999. Также добавим в хеш-таблицу элементы с ключом 0, 5120 и 9999 соответственно. После чего произведём поиск данных элементов (первого элемента, элемента «где-то посередине» и последнего элемента соответственно) и посчитаем затрачиваемое время для каждого поиска.

```
import time
import random
for i in range(10000):
    b: bool = random.randint(0, 1)
    if b == 1:
        hs.add(i, 'example', 'example')
hs.add(0, 'aaa', 'ddd')
hs.add(5120, 'bbb', 'eee')
hs.add(9999, 'ccc', 'fff')
print()

start = time.time()
print(hs.get(0))
result = time.time() - start
print("Program time: {:>.5f}".format(result) + " seconds.")

start = time.time()
print(hs.get(5120))
result = time.time() - start
print("Program time: {:>.5f}".format(result) + " seconds.")

start = time.time()
print(hs.get(9999))
result = time.time() - start
print("Program time: {:>.5f}".format(result) + " seconds.")
```

Рисунок 6 – Код для проверки на время работы метода получения элемента.

В результате было выяснено, что время доступа для всех записей одинаково.

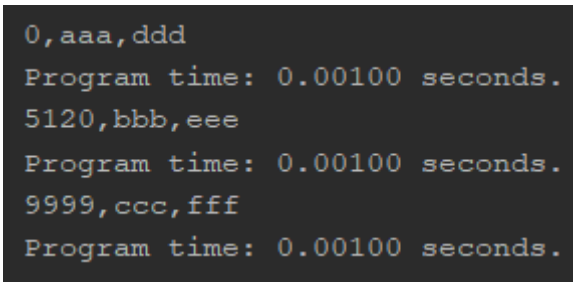

Рисунок 7 – Время получения разных элементов.

Вывод

В ходе работы были приобретены практические навыки по использованию хеш-таблиц и их применению.

Список информационных источников

1. Лекции по дисциплине «Структуры и алгоритмы обработки данных» / Л. А. Скворцова, МИРЭА – Российский технологический университет, 2021.